

林晓舟

北京 · 8 年经验 · 138****0000 · lin@example.com

AI Agent 开发工程师 · 全栈工程背景

核心技术

LangGraph / RAG / FastAPI / Python / PostgreSQL / MCP / SSE /
RTC

个人优势

- 熟悉 AI 应用落地，能够将模型能力接入具体业务流程。
- 熟悉 Python、FastAPI、asyncio 与 Pydantic，具备异步接口和流式输出经验。
- 熟悉 RAG 数据清洗、文档切片、Embedding、混合检索和 Rerank 优化。
- 具备 Prompt 版本管理、自动化评测和负样本优化经验。
- 熟悉 LangGraph 工作流编排，具备子图拆分、状态持久化和节点重试经验。
- 具备 Vue、TypeScript 前端开发经验，可完成 AI 对话界面和流式渲染。
- 具备 RTC、ASR、TTS 实时语音应用经验，熟悉链路异常处理。
- 关注 AI 服务可观测性，能够通过日志、Trace、限流和熔断保障稳定性。

技术栈

Agent 与编排：LangGraph、LangChain、MCP、Tool Calling

RAG 与推理：Embedding、HNSW、Rerank、Metadata、Prefix Cache

后端与数据：Python、FastAPI、PostgreSQL、SSE、WebSocket

前端与工程：Vue、TypeScript、Git、监控、熔断与重试

AI Agent 项目实践

业务输入	处理与项目能力	AI 资产	线上应用
商户与商品数据 内容运营需求 历史咨询数据	知识数据加工 内容生产 workflow 数据清洗与微调	RAG 知识库 LoRA 微调模型 评测数据集	实时语音导购 Agent 内容运营系统 智能问答

项目经历

实时语音导购 Agent 核心开发

2025.03 - 2026.07

围绕到店决策场景，串联 RTC、ASR、RAG、LLM 与 TTS。

- 构建混合检索方案，通过量化与 Metadata 过滤将向量存储空间降低 75%，检索速度提升 4 倍。
- 优化检索片段与 System Prompt，将复杂 RAG 场景 TTFT 从 8 秒降低至 2 秒内。
- 建立提示词版本、评测集和负样本优化闭环，支持问题回放与快速迭代。
- 完成 RTC、ASR、LLM、TTS 实时链路联调与异常处理。

智能内容运营系统 核心开发

2025.03 - 2026.07

使用 LangGraph 构建选题、写作、配图与审核的一体化生产工作流。

- 使用 SubGraph 拆分业务单元，并通过 PostgreSQL Checkpointer 持久化状态。
- 集成 SSE 流式输出，用户感知 TTFT 降低 60%。
- 通过并发生成和指数退避重试，整体生成耗时缩减 70%。
- 使用 Pydantic Schema 约束结构化输出，降低多模型切换成本。

基于聊天数据的大模型微调 核心开发

2025.06 - 2026.07

围绕商家风格一致性和门店知识准确性，完成数据清洗、微调与评测。

- 通过消息过滤、时间窗口与语义切分筛选多轮对话，脱敏准确率达到 98%。
- 使用 LLaMA-Factory 对指令模型进行 LoRA 微调，并建立人工评测流程。
- 拆分风格数据与 RAG 知识数据，使表达风格和动态知识分别迭代。
- 引入 Cross-Encoder 精排改善知识召回结果排序。

工作经历

前端开发工程师 / AI 应用开发 示例科技有限公司

2021.09 - 2026.07

负责业务前端与 AI Agent 应用研发。

- 主导多端适配和组件体系建设，持续提升交付效率。
- 参与语音导购、内容运营和模型评测等 AI Agent 项目。

前端开发工程师 示例网络科技有限公司

2018.06 - 2021.09

负责 H5、PC 和国际化业务开发。

- 完成多语言和性能优化建设，首屏加载速度提升 50%。

前端开发工程师 示例文化传播有限公司

2020.12 - 2021.09

负责在线教育作业批改与教师培训业务。

- 实现支持拖动、评论和图片分享的在线作业批改功能。
- 封装富文本编辑器并处理 Web 与移动端数据协议转换。

前端开发工程师 示例网络科技有限公司

2018.06 - 2020.12

负责电商小程序、H5 活动页和后台管理系统。

- 持续优化首页性能与复杂业务交互，支持千万级日订单场景。

教育经历

示例大学

2014 - 2018

计算机科学与技术 · 本科