

林晓舟

AI Agent 开发工程师 · 全栈工程
背景

北京
8 年经验
138****0000
lin@example.com

核心技术
LangGraph / RAG / FastAPI / Python /
PostgreSQL / MCP / SSE / RTC

个人优势

- 熟悉 AI 应用落地，能够将模型能力接入具体业务流程。
- 熟悉 Python、FastAPI、asyncio 与 Pydantic，具备异步接口和流式输出经验。
- 熟悉 RAG 数据清洗、文档切片、Embedding、混合检索和 Rerank 优化。
- 具备 Prompt 版本管理、自动化评测和负样本优化经验。
- 熟悉 LangGraph 工作流编排，具备子图拆分、状态持久化和节点重试经验。
- 具备 Vue、TypeScript 前端开发经验，可完成 AI 对话界面和流式渲染。
- 具备 RTC、ASR、TTS 实时语音应用经验，熟悉链路异常处理。
- 关注 AI 服务可观测性，能够通过日志、Trace、限流和熔断保障稳定性。

技术栈

Agent 与编排: LangGraph、LangChain、MCP、Tool Calling

后端与数据: Python、FastAPI、PostgreSQL、SSE、WebSocket

RAG 与推理: Embedding、HNSW、Rerank、Metadata、Prefix Cache

前端与工程: Vue、TypeScript、Git、监控、熔断与重试

AI Agent 项目实践

业务输入	处理与项目能力	AI 资产	线上应用
商户与商品数据 内容运营需求 历史咨询数据	知识数据加工 内容生产工作流 数据清洗与微调	RAG 知识库 LoRA 微调模型 评测数据集	实时语音导购 Agent 内容运营系统 智能问答

— 项目经历

实时语音导购 Agent 核心开发

2025.03 – 2026.07

围绕到店决策场景，串联 RTC、ASR、RAG、LLM 与 TTS。

- 构建混合检索方案，通过量化与 Metadata 过滤将向量存储空间降低 75%，检索速度提升 4 倍。
- 优化检索片段与 System Prompt，将复杂 RAG 场景 TTFT 从 8 秒降低至 2 秒内。
- 建立提示词版本、评测集和负样本优化闭环，支持问题回放与快速迭代。
- 完成 RTC、ASR、LLM、TTS 实时链路联调与异常处理。

智能内容运营系统 核心开发

2025.03 – 2026.07

使用 LangGraph 构建选题、写作、配图与审核的一体化生产工作流。

- 使用 SubGraph 拆分业务单元，并通过 PostgreSQL Checkpointer 持久化状态。
- 集成 SSE 流式输出，用户感知 TTFT 降低 60%。
- 通过并发生成和指数退避重试，整体生成耗时缩减 70%。
- 使用 Pydantic Schema 约束结构化输出，降低多模型切换成本。

基于聊天数据的大模型微调 核心开发

2025.06 – 2026.07

围绕商家风格一致性和门店知识准确性，完成数据清洗、微调与评测。

- 通过消息过滤、时间窗口与语义切分筛选多轮对话，脱敏准确率达到 98%。
- 使用 LLaMA-Factory 对指令模型进行 LoRA 微调，并建立人工评测流程。
- 拆分风格数据与 RAG 知识数据，使表达风格和动态知识分别迭代。
- 引入 Cross-Encoder 精排改善知识召回结果排序。

— 工作经历

前端开发工程师 / AI 应用开发 示例科技有限公司

2021.09 – 2026.07

负责业务前端与 AI Agent 应用研发。

- 主导多端适配和组件体系建设，持续提升交付效率。
- 参与语音导购、内容运营和模型评测等 AI Agent 项目。

前端开发工程师 示例网络科技有限公司

2018.06 – 2021.09

负责 H5、PC 和国际化业务开发。

- 完成多语言和性能优化建设，首屏加载速度提升 50%。

前端开发工程师 示例文化传播有限公司

2020.12 – 2021.09

负责在线教育作业批改与教师培训业务。

- 实现支持拖动、评论和图片分享的在线作业批改功能。
- 封装富文本编辑器并处理 Web 与移动端数据协议转换。

前端开发工程师 示例网络科技有限公司

2018.06 – 2020.12

负责电商小程序、H5 活动页和后台管理系统。

- 持续优化首页性能与复杂业务交互，支持千万级日订单场景。

— 教育经历

示例大学 计算机科学与技术 · 本科

2014 – 2018